

Lecture Notes 5

Minfei Chen

2025 年 8 月 21 日

1 Monte Carlo estimation

蒙特卡洛方法实际上是一种用采样的数据来估计模型的 **model-free** 的方法。

2 MC basic

算法的关键在于用 model-free 的方法来求解 q_{π_k} ，即从采样中获得 discounted return 的估计。

- 从一个状态-动作对 (s, a) 出发，遵循策略 π_k ，生成一条完整的经验片段 (episode)。
- 该经验片段从 (s, a) 开始的总回报 (return) 为 $g(s, a)$ 。
- 这个计算出的 $g(s, a)$ 是真实期望总回报 G_t 的一个样本 (sample)。

根据定义，动作价值函数 $q_{\pi_k}(s, a)$ 是期望总回报：

$$q_{\pi_k}(s, a) = \mathbb{E}[G_t | S_t = s, A_t = a]$$

- 假设我们通过多次试验，有了一系列经验片段，因此也就有了一组从 (s, a) 出发的回报样本 $\{g^{(j)}(s, a)\}$ 。那么，我们可以通过求平均来近似计算 Q 函数：

$$\begin{aligned} q_{\pi_k}(s, a) &= \mathbb{E}[G_t | S_t = s, A_t = a] \\ &\approx \frac{1}{N} \sum_{i=1}^N g^{(i)}(s, a). \end{aligned}$$

* 在这个方法中，我们不计算 policy iteration 中的 v_{π_k} ，而是直接从样本估计出 q_{π_k} 。

3 MC Exploring Starts

Visit：对于所有状态和行动的组合作，执行一次叫做一个 visit。

Initial-visit method:

把每一个 episode 视为只包含了第一个 visit 的信息（即 MC Basic）实际上对 episode 的信息利用是不充分的。如果把后续的步数也看成是不同的 episode，就可以比较充分地利用整个 episode 的信息。

举一个例子：

$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots$ [原始经验片段 (original episode)]

$s_2 \xrightarrow{a_4} s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots$ [从 (s_2, a_4) 开始的片段]

$s_1 \xrightarrow{a_2} s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots$ [从 (s_1, a_2) 开始的片段]

$s_2 \xrightarrow{a_3} s_5 \xrightarrow{a_1} \dots$ [从 (s_2, a_3) 开始的片段]

$s_5 \xrightarrow{a_1} \dots$ [从 (s_5, a_1) 开始的片段]

可以估计 (Can estimate) $q_{\pi}(s_1, a_2), q_{\pi}(s_2, a_4), q_{\pi}(s_2, a_3), q_{\pi}(s_5, a_1), \dots$

* 包含 first visit (只利用 visit 第一次出现时后续的信息) 和 every visit (不管出现多少次都利用后续的信息) 两种方法

Exploring 的含义：确保每一个 (s, a) 都能被访问到。

starts 的含义：确保 episode 是从 (s, a) 开始的

4 MC ϵ -greedy

什么是 ϵ -贪心策略？

一个 ϵ -贪心策略 π 在给定状态 s 下，选择动作 a 的概率定义如下：

$$\pi(a|s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{对于贪心动作 (greedy action)} \\ \frac{\epsilon}{|A(s)|} & \text{对于其他 } |A(s)| - 1 \text{ 个非贪心动作} \end{cases}$$

如何将 ϵ -贪心策略嵌入到 MC 算法中?

现在, 策略提升步骤被修改为求解以下问题:

$$\pi_{k+1}(s) = \arg \max_{\pi \in \Pi_\epsilon} \sum_a \pi(a|s) q_{\pi_k}(s, a)$$

其中 Π_ϵ 表示所有 ϵ -贪心策略的集合 (具有一个固定的 ϵ 值)。

在这个约束下, 提升后的最优策略 π_{k+1} 具有如下形式:

$$\pi_{k+1}(a|s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{如果 } a = a_k^* \\ \frac{\epsilon}{|A(s)|} & \text{如果 } a \neq a_k^* \end{cases}$$

这里的 a_k^* 是指在当前价值评估 q_{π_k} 下的贪心动作, 即 $a_k^*(s) = \arg \max_a q_{\pi_k}(s, a)$ 。

和 MC exploring starts 的区别: 探索性, 不需要从所有 (s, a) 出发, 也能确保遍历到比较多的特定的 (s, a)

* 在 MC ϵ -greedy 中, 使用 every visit 方法来利用数据