

Lecture Notes 6

Minfei Chen

2025 年 8 月 24 日

1 Robins Monro Algorithm

RM 算法是 Stochastic Approximation 领域的工作。

SGD 随机梯度下降是 RM 算法的特殊形式。

Robbins-Monro (RM) 算法可以解决以下问题：

$$w_{k+1} = w_k - a_k \tilde{g}(w_k, \eta_k), \quad k = 1, 2, 3, \dots$$

其中：

- w_k 是对“根”(root) 的第 k 次估计值。
- $\tilde{g}(w_k, \eta_k) = g(w_k) + \eta_k$ 是第 k 次带噪声的观测值 (noisy observation)。
- a_k 是一个正系数（通常称为步长或学习率）。

1.1 收敛性分析

Robbins-Monro (RM) 定理说明在以下随机迭代过程中：

$$w_{k+1} = w_k - a_k (g(w_k) + \eta_k), \quad k = 1, 2, 3, \dots$$

如果满足一定条件，则 w_k 收敛到满足 $g(w^*) = 0$ 的解 w^* 。

其中：

- w_k 是第 k 次迭代得到的估计值。
- a_k 是正的步长序列（学习率），需满足

$$\sum_{k=1}^{\infty} a_k = \infty, \quad \sum_{k=1}^{\infty} a_k^2 < \infty$$

- η_k 是随机噪声, 满足

$$\mathbb{E}[\eta_k | \mathcal{H}_k] = 0, \quad \mathbb{E}[\eta_k^2 | \mathcal{H}_k] < \infty,$$

其中 $\mathcal{H}_k = \{w_k, w_{k-1}, \dots\}$ 表示历史信息。

- 假设存在常数 $0 < c_1 \leq c_2$, 使得

$$c_1 \leq \nabla_w g(w) \leq c_2 \quad \text{对所有 } w \text{ 成立}$$

在上述条件下, 迭代序列 $\{w_k\}$ 将以概率 1 收敛到满足

$$g(w^*) = 0$$

的解 w^* 。

2 随机梯度下降(stochastic gradient decent,SGD)

2.1 SGD 的概念和公式

随机梯度下降是梯度下降的其中一种方法, 而使用梯度下降的目的是求出目标函数的最小值 w^* 随机梯度下降的公式:

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

与梯度下降 (GD) 与批量梯度下降 (BGD) 的区别: 不计算期望 (即梯度的真实值), 而是只使用了一个采样

* 实际上批量梯度下降也只是用采样来估计梯度

2.2 收敛性分析

思路: 证明 SGD 是解决一个特殊问题 (梯度 = 0) 的 RM 算法。

第一步: 将 SGD 的最小化问题转化为寻根问题

SGD 的目标是最小化目标函数 $J(w)$, 即在所有数据 X 上的期望损失:

$$J(w) = \mathbb{E}[f(w, X)]$$

这个最小化问题可以被转化为一个寻根问题。根据微积分原理，函数在最小值点，其梯度为零。因此，我们需要找到 w 使得：

$$\nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0$$

现在，我们令：

$$g(w) = \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)].$$

于是，SGD 的目标就变成了：寻找函数 $g(w) = 0$ 的根。

第二步：使用 RM 算法求解该寻根问题

无法计算真实的梯度 $g(w)$ （因为它需要在所有数据上求期望），我们能测量到的只是在单个样本 x 上的随机梯度：

$$\tilde{g}(w, \eta) = \nabla_w f(w, x)$$

将这个随机梯度分解为真实梯度和噪声项：

$$\tilde{g}(w, \eta) = \underbrace{\mathbb{E}[\nabla_w f(w, X)]}_{g(w)} + \underbrace{\nabla_w f(w, x) - \mathbb{E}[\nabla_w f(w, X)]}_{\eta}.$$

这里的噪声项 η 的期望为零。

使用 RM 算法来求解 $g(w) = 0$ ：

$$w_{k+1} = w_k - a_k \tilde{g}(w_k, \eta_k) = w_k - a_k \nabla_w f(w_k, x_k).$$

这个结果正是 SGD 算法的更新规则。

2.2.1 梯度误差与实际误差

我们定义随机梯度的相对误差 δ_k 为：

$$\delta_k := \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)]|}.$$

由于在最优点 w^* 处，我们有 $\mathbb{E}[\nabla_w f(w^*, X)] = 0$ ，可以进一步推得：

$$\begin{aligned} \delta_k &= \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w f(w_k, X)] - \mathbb{E}[\nabla_w f(w^*, X)]|} \\ &= \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{|\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]|}. \end{aligned}$$

其中最后一个等式是根据中值定理 (mean value theorem) 得到的, 并且 $\tilde{w}_k \in [w_k, w^*]$ 。假设函数 f 是**严格凸 (strictly convex)** 的, 满足:

$$\nabla_w^2 f \geq c > 0$$

对于所有的 w, X 均成立, 其中 c 是一个正常数下界。

那么, 上一节中 δ_k 的分母可以进行如下放缩:

$$\begin{aligned} |\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)(w_k - w^*)]| &= |\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)](w_k - w^*)| \\ &= |\mathbb{E}[\nabla_w^2 f(\tilde{w}_k, X)]| \cdot |w_k - w^*| \\ &\geq c|w_k - w^*|. \end{aligned}$$

将上述不等式代入 δ_k 的定义, 可得其上界:

$$\delta_k \leq \frac{|\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]|}{c|w_k - w^*|}$$

由此可得, 当 w_k 与 W^* 距离较远的时候, 随机梯度是接近于真实梯度 (期望) 的。**此时 SGD 就近似于 GD**。此时梯度下降的方向大致会朝着正确的方向。

而当 w_k 与 W^* 距离较近的时候, 随机梯度的随机性则会有所提高。此时梯度下降的方向也会比较随机。

2.3 BGD, MBGD and SGD

假设我们想要最小化目标函数 $J(w) = \mathbb{E}[f(w, X)]$, 并且给定了一组来自 X 的随机样本 $\{x_i\}_{i=1}^n$ 。用于解决该问题的 BGD、SGD 和 MBGD 算法分别如下:

- **批量梯度下降 (Batch Gradient Descent, BGD):**

$$w_{k+1} = w_k - \alpha_k \frac{1}{n} \sum_{i=1}^n \nabla_w f(w_k, x_i)$$

- **小批量梯度下降 (Mini-Batch Gradient Descent, MBGD):**

$$w_{k+1} = w_k - \alpha_k \frac{1}{m} \sum_{j \in \mathcal{I}_k} \nabla_w f(w_k, x_j)$$

- 随机梯度下降 (Stochastic Gradient Descent, SGD):

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

如果批量大小 $m = 1$ ，那么小批量梯度下降 (MBGD) 就变成了随机梯度下降 (SGD)。

如果批量大小 $m = n$ （即等于总样本数），严格来说，MBGD 并不会变成批量梯度下降 (BGD)。

这是因为 MBGD 的定义是使用随机抽取的 n 个样本，而 BGD 使用的是固定的全部 n 个样本。特别地，MBGD 可能会在一次更新中多次使用数据集 $\{x_i\}_{i=1}^n$ 里的同一个样本（即有放回采样），而 BGD 在一次更新中对每个样本只使用一次。